

Team12 NLP 期末書面報告

第十二組組員: 林鼎翔、褚柏均

摘要

本研究以 HITSZ-HLT 於 SIGHAN 2024 Dimensional ABSA shared task 的系統為主要參考，該研究指出「以 BERT 負責抽取與分類、以 LLM 負責 Valence-Arousal(VA)強度」的 pipeline 通常優於「單用 BERT 或單用 LLM 做全任務」的端到端策略。

我們依循這個思路，實作由多個子模型組成的 pipeline 架構：Aspect/Opinion 以 BIO 標註的形式進行抽取；Category 與 Relation 以分類器完成類別判定與配對；VA 以 QLoRA 微調後的 LLM 輸出 V#A 格式。

在實驗中，我們嘗試使用「加入負樣本訓練 relation classifier」來改善任務表現，但更進一步的 hard negative mining 與 prompt 調整並未穩定提升，整體表現不如預期。本文整理系統流程、實驗設定、結果與失敗原因，並提出後續可行改進方向。

1. 引言

1.1 問題定義

本任務目標是在給定文本中輸出多個四元組：Aspect、Category、Opinion、VA (Valence/Arousal)。參考論文的共享任務設定亦採相同核心結構，並以此作為評估輸出正確性的依據。

1.2 動機

過去常見兩種極端做法：以 Transformer/BERT 類模型「分別」處理抽取、分類、回歸等子任務；以 LLM 直接生成完整結構化答案。參考論文的結論指出：以 BERT 類模型處理抽取/分類 + 以 LLM 處理 VA 強度的整合式 pipeline 通常最佳。因此，我們以「可控、可拆解 debug」為主軸，採用可模組化替換的 pipeline 設計，並在實驗中逐步替換 Transformer / LLM 與負樣本策略觀察影響。

2. 相關工作與參考論文方法

2.1 HITSZ-HLT (SIGHAN 2024.sighan-1.20) 方法概述

參考論文將任務拆成多個子模組，對於不同子任務用最合適的模型：抽取/分類(如 aspect boundary、category、relation)以 BERT 類模型處理；VA 強度以 LLM 透過指令式輸出(論文採 code-style 指令)處理。此外，該方法也強調資料與訓練技巧：例如收集大量評論句做 domain-adaptive pretraining 以提升在目標 domain 的表現。

2.2 參考論文對本研究的啟發

我們主要借鑒了參考論文的兩大核心策略：

- Pipeline：把可控的抽取/分類交給 Transformer，把 VA 預測交給 LLM。
- 負樣本/INVALID 設計：relation 任務若沒有足夠「看起來很像正例」的負例，很容易造成配對錯誤；因此需要系統化地生成 INVALID pairs 來訓練。

3. 方法

3.1 系統總覽

本研究系統架構如圖 1：(1)輸入句子先經 Transformer encoder；(2)以 Aspect BIO tagger 與 Opinion BIO tagger 產生候選片段 a 與 o；(3)將候選 (a,o) 與句子組合成配對輸入，使用 Relation pairing classifier 判定是否為有效四元組；(4)有效配對再餵給 LLM，輸出 V#A 作為 VA 預測。




圖 1. 本研究系統流程圖。圖中展示了從輸入句子到輸出四元組的完整步驟。

3.2 BIO 抽取 (Aspect / Opinion)

Aspect 與 Opinion 抽取皆以 token classification 形式訓練。我們將金標 quadruplet 中的 Aspect/Opinion 片段對齊回原文位置，再轉換為 BIO 標註。推論時將連續 B/I 序列解碼為 span，作為後續配對候選。

3.3 Relation 配對分類

Relation classifier 以「句子 + (aspect, opinion)」為輸入，預測其對應的 Category 或 INVALID。為凸顯邊界，我們在原句中插入 [ASP]...[/ASP] 與 [OPN]...[/OPN] 標記，並以「marked_text」作為第一序列、以「aspect [SEP] opinion」作為第二序列進行分類。此設計能在同一句中區分不同配對組合。

3.4 建立負樣本

為訓練 INVALID 類別，我們採用 k-fold 方式先訓練簡易 BIO 模型，再在各 fold 的驗證資料上推論得到多個候選 aspect/opinion span，並將組合中非金標配對者標為 INVALID，每句最多保留固定數量的負樣本以控制訓練品質。

3.5 Category classifier 與 fallback

當 relation classifier 對某句所有候選配對皆預測為 INVALID，系統有設計 fallback：先以 category classifier 對每個 aspect 預測類別，再依照最短距離將 opinion 指派給 aspect，以避免輸出為空。

3.6 VA 預測 (QLoRA 微調 LLM)

VA 模組使用 instruct-style prompt，令 LLM 輸出單行 V#A(例如 6.5#6.0)。我們使用 QLoRA 進行 SFT 微調，並在推論時以正則式擷取 V#A；若解析失敗則回退 5.0#5.0。此外，針對不同 LLM backbone，我們亦嘗試對多個 VA 結果取平均(mean ensemble)。

4. 實驗

4.1 資料與評估

模型性能評估採用官方開發集 (Dev Set) 的標準評估指標：四元組級別的精確率 (Quadruplet-level Precision, cPrecision)、召回率 (Quadruplet-level Recall, cRecall)，以及 F1 分數 (cF1)，藉此對不同模型的配置進行比較與分析。

為了掌握資料集特性，我們參考 Overview of the SIGHAN 與 HITSZ-HLT 系統報告的呈現方式，將訓練資料的 (a) aspect category 分佈與 (b) valence–arousal 強度分佈進行可視化。在本任務中，情緒強度以 valence 與 arousal 的 1~9 量表表示，並以 valence#arousal 格式儲存。




圖 2a. Laptop 資料集 Category 分佈。僅展示出現頻率最高的前 10 類，其餘合併為 Others。





圖 2b. Laptop 資料集 VA 分佈。

對 Laptop 而言 (圖 2a)，category 的種類更分散，因此我們僅展示出現頻率最高的前 10 類並將其餘合併為 Others，以提升可讀性；圖 2b 的 VA 分佈與 Restaurant 類似，均呈



現弧形趨勢。


圖 3a. Restaurant 資料集 Category 分佈。僅展示出現頻率最高的前 10 類，其餘合併為 Others。

圖 3b. Restaurant 資料集 VA 分佈。

就 Restaurant 而言 (圖 3a)，類別分佈高度不均衡，FOOD#QUALITY 佔比明顯最高，其餘類別呈現長尾；在強度分佈方面 (圖 3b)，valence-arousal 散點呈現相似的曲線趨勢：高正向與高負向樣本通常伴隨較高 arousal (V型/弧形分佈)，亦與 overview 的觀察相符。

4.2 訓練細節與超參數設定

Transformer pipeline 預設使用 num_epochs=5、train_batch_size=8、learning_rate=1e-5、



weight_decay=0.01、max_length=256，優化器為 AdamW。

VA LLM 微調採 QLoRA SFT，預設為 num_epochs=5、per_device_train_batch_size=1、gradient_accumulation_steps=8、learning_rate=1e-4、warmup_ratio=0.05，並支援 4-bit 載入以降低記憶體需求。

4.3 模型配置與實驗

由於系統由多個子模組組成，我們採用一次只替換一個模組的對照設計，以 dev 的 cPrecision/cRecall/cF1 觀察差異：(1) Transformer backbone：在 BIO 與分類器上嘗試多個中文預訓練 encoder，並固定 VA LLM 為 Llama-3.1-8B-Instruct。實驗結果記錄在表一。(2) 負樣本訓練：選定最佳Transformer Backbone後，我們針對 Relation Pairing Classifier 進行了負樣本訓練。實驗結果記錄在表二。(3) VA LLM：在固定 Transformer

pipeline 後，替換不同 LLM backbone 微調/推論 VA，為降低生成方差，我們額外實作 mean ensemble，對同一 (sentence, aspect, opinion) 的多個 LLM 輸出分別取平均 Valence 與 Arousal，再回寫到 quadruplet。實驗結果記錄在表三。

Transformer	Laptop			Restaurant		
	cP	cR	cF1	cP	cR	cF1
BERT-base	0.2656	0.2618	0.2637	0.4366	0.4263	0.4314
RoBERTa-wwm-ext	0.2881	0.2913	0.2897	0.4155	0.4106	0.4131
RoBERTa-large	0.2962	0.3166	0.3061	0.4342	0.4262	0.4301
ERNIE-base	0.2621	0.283	0.2721	0.4266	0.4266	0.4266
ERNIE-xbase	0.3095	0.3314	0.3201	0.4462	0.4374	0.4418
DeBERTa	0.2677	0.2609	0.2643	0.4162	0.4037	0.4099

表 1：固定 VA LLM=Llama-3.1-8B-Instruct 下，不同 Transformer backbone 的 dev 表現。cP 為 四元組級別精確率/cPrecision, cR 為四元組級別召回率/cRecall, cF1 為四元組級別 F1 分數

從表 1 中可見，在所有測試的 Backbone 中，ERNIE-3.0-xbase-zh 在兩個資料集上均表現最佳，取得了最高的 cF1 分數。因此，在後續 VA 模組的實驗中，我們將 Transformer pipeline 固定為 ERNIE-3.0-xbase-zh。

Methods	Laptop			Restaurant		
	cP	cR	cF1	cP	cR	cF1
BERT+LLM (w/o negative sample)	0.3095	0.3314	0.3201	0.4462	0.4374	0.4418
BERT+LLM (w/ negative sample)	0.4193	0.3736	0.3951	0.5478	0.5169	0.5319

表 2：加入負樣本的實驗，固定 Transformer=ERNIE-3.0-xbase-zh、LLM=Llama-3.1-8B-Instruct。

從表 2 可見，若 relation classifier 在訓練時加入 INVALID 負樣本，兩個資料集的 cF1 分數皆出現顯著提升。其中，精確率 (cP) 的上升幅度尤為明顯，Laptop 提升約 11 個百分點，Restaurant 提升約 10 個百分點。這表明 INVALID 負樣本在訓練過程中扮演了關鍵角色，有效提升了模型區分有效四元組與雜訊配對的能力，從而大幅改善了配對的準確性。

Model	Laptop			Restaurant		
	cP	cR	cF1	cP	cR	cF1
Llama 3.1-8	0.4151	0.3699	0.3912	0.5436	0.5129	0.5278
Qwen-14B	0.4164	0.3711	0.3924	0.5444	0.5136	0.5285
Phi-4	0.4182	0.3727	0.3941	0.5445	0.5137	0.5287
DeepSeek-7B	0.4165	0.3712	0.3925	0.5423	0.5117	0.5266
Ensemble	0.4193	0.3736	0.3951	0.5478	0.5169	0.5319

表 3：固定 Transformer=ERNIE-3.0-xbase-zh 下，不同 VA LLM 的最終表現

表 3 結果顯示，所有 LLM 的單一表現差異不大，但 Mean Ensemble 策略成功在兩個資料集上帶來一致的小幅性能增益 Laptop cF1 提升至 0.3940，Restaurant cF1 提升至 0.5319，證明了集成方法對於穩定 VA 預測結果的有效性。

4.4 Hard Negative Mining 設定

在 +INVALID 的基礎上，我們進一步嘗試 Hard Negative Mining 作為 improve。使用第一階段 relation classifier 的輸出機率，從 INVALID 中挑出「最像正例」的負例，再進行第二階段訓練以強化 decision boundary。此想法參考 Meghwani et al. (2025) 的 hard negative mining 概念。

本策略基於第一階段訓練完成的 Relation classifier，從其對 INVALID 候選配對的輸出機率中，篩選出難度最高的負例，進行第二階段微調，以強化決策邊界。難度 (hardness) 定義為該配對被分類為任何一個有效類別的最高機率。

$$h_{\text{INVALID}} = \max(\text{INVALID} - \text{VALID})$$

每句最多挑選 8 個 Hard Negative 樣本。第二階段訓練僅對 Relation classifier 進行微調，其餘模組保持固定。表 4 展示了此策略對最終四元組性能指標的影響，其中基線為已加入 INVALID 負樣本的最終系統配置，固定 Transformer=ERNIE-3.0-xbase-zh、VA

Methods	Laptop			Restaurant		
	cP	cR	cF1	cP	cR	cF1
BERT+LLM(+INVALID)	0.4193	0.3736	0.3951	0.5478	0.5169	0.5319
BERT+LLM(+INVALID+HNM)	0.1399	0.3116	0.1927	0.2186	0.4659	0.2973

LLM=Llama-3.1-8B-Instruct，並實驗於 laptop 資料集上。

表 4：Hard Negative Mining (+HNM) 對最終分數的影響

我們觀察到 HNM 策略並未能穩定提升最終的 cF1 分數。推測其原因在於，系統的主要錯誤來源並非來自 Relation classifier 的決策邊界不夠精細，而是來自於上游 Span 邊界與切分問題，導致許多正確的四元組在 Relation classifier 之前就已缺失，使 Relation classifier 無法僅通過精修自身邏輯來彌補。

就結果而言，Laptop 訓練資料的類別分佈較 Restaurant 分散 (如圖 3a、3b)，可能使 category、relation 判定更具挑戰，這也與兩個 domain 在整體 cF1 表現存在差異的現象相呼應。

5. 錯誤分析

我們針對錯誤的案例進行分析，歸納出以下常見失敗型態(錯誤案例放置在附錄A中)：

- (1) 邊界與字串微差導致 Missing/Extra 同時出現。在長文本或口語句中，模型容易抽到「語意相近但字串不同」的片段(例如多了「已經」、或少了後綴)，在嚴格 exact-match 的評分下會同時造成 Missing 與 Extra。
- (2) 長句多面向評論的召回不足。當一句包含多個 aspect/opinion 時，BIO 抽取與配對過濾都可能降低召回，導致最終輸出四元組數量偏少。可考慮提高候選保留上限、對長句採 sliding-window、或調整 INVALID 過濾策略。
- (3) 過度切分造成重複輸出與配對污染。部分樣本會把單一實體(如型號)切成多個短 aspect(例如「輕」「攜帶」)，造成大量冗餘四元組與 extra。可加入 span 合併與去重後處理。
- (4) Category 歧義與同一 aspect 多類別。同一 aspect 在不同 opinion 下可能對應不同 category(例如「觸控板」同時涉及操作表現、設計特性與一般評價)，若模型傾向單一類別，容易出現 category mismatch。可強化以(sentence, aspect, opinion)條件化的類別判斷。

6. 結論

我們參考 SIGHAN-2024 第一名的做法，使用負樣本進行訓練，用 Transformer (BIO tagger, Relation Pairing classifier, Category classifier) 和 LLM 建立 Pipeline 的架構，並測試多個不同模型在 Pipeline 結構下的表現。實驗顯示 INVALID 負樣本訓練能有效提升 relation 配對品質；VA 的 mean ensemble 可帶來一致的小幅增益。最終使用 ernie-3.0-xbase-zh 和多個 LLM 對 VA 預測做 Ensemble，當作提交在 CodaBench 上的模型，也是表現最好的組合。

參考文獻

Xu, Hongling, Delong Zhang, Yice Zhang, and Ruifeng Xu. 2024. HITSZ-HLT at SIGHAN-2024 dimABSA Task: Integrating BERT and LLM for Chinese Dimensional Aspect-Based Sentiment Analysis. In Proceedings of the 10th SIGHAN Workshop on Chinese Language Processing (SIGHAN-10), pages 175–185, Bangkok, Thailand. Association for Computational Linguistics.

Meghwani, Hansa, Amit Agarwal, Priyaranjan Pattnayak, Hitesh Laxmichand Patel, and Srikant Panda. 2025. Hard Negative Mining for Domain-Specific Retrieval in Enterprise Systems. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 6: Industry Track), pages 1013–1026, Vienna, Austria. Association for Computational Linguistics.

Lee, Lung-Hao, et al. 2024. Overview of the SIGHAN 2024 shared task for Chinese dimensional aspect-based sentiment analysis. (2024.sighan-1.19)

附錄 A：錯誤案例(節錄)

A.1：

長文本多面向；多個 gold quadruplet 未被召回，且 opinion 字串有微差(例如「算還行」vs「已經算還行」)。

Input：

舊13/14th耗電...續航都不怎樣...2XX系的內顯效能已經算還行，輕量應用沒啥問題...GPU配8GB記憶體...FPS下降...

Gold：

2XX系的內顯效能 | GRAPHICS#OPERATION_PERFORMANCE | 算還行

續航 | BATTERY#OPERATION_PERFORMANCE | 會好很多

GPU配8GB記憶體 | GRAPHICS#OPERATION_PERFORMANCE | ...FPS下降

Pred：

2XX系的內顯效能 | GRAPHICS#OPERATION_PERFORMANCE | 已經算還行

A.2：

過度切分與重複輸出：UM5302LA/輕/攜帶 等造成大量 extra；gold 的「輕薄好攜帶」被拆開。

Input :

...UM5302LA...性能上和輕薄好攜帶都完全沒問題...充電器超方便好攜帶...

Gold :

UM5302LA | LAPTOP#PORTABILITY | 輕薄好攜帶

充電器 | POWER_SUPPLY#PORTABILITY | 超方便好攜帶

Pred :

UM5302LA | LAPTOP#PORTABILITY | 輕薄

UM5302LA | LAPTOP#PORTABILITY | 好攜帶

輕 | LAPTOP#PORTABILITY | 輕薄

攜帶 | LAPTOP#PORTABILITY | 完全沒問題

A.3 :

Category mismatch : 同一觸控板對應多類別，預測集中在 DESIGN_FEATURES。

Input :

觸控板挺滑順，按壓感紮實，沒什麼好挑剔的。

Gold :

觸控板 | **HARDWARE#OPERATION_PERFORMANCE** | 挺滑順

觸控板 | **HARDWARE#DESIGN_FEATURES** | 按壓感紮實

觸控板 | **HARDWARE#GENERAL** | 沒什麼好挑剔的

Pred :

觸控板 | HARDWARE#DESIGN_FEATURES | 挺滑順

觸控板 | HARDWARE#DESIGN_FEATURES | 沒什麼好挑剔的